TUGAS 1 — SISTEM TEMU KEMBALI INFORMASI (INFORMATION RETRIEVAL)

Laporan Crawling Data Dokumen Web: Koleksi Artikel Musik Indonesia dari ANTARA News

Nama Kelompok	: Kelompok [Nama/Nomor Kelompok]
Anggota Tim	: 1. [Nama Anggota 1 - NIM] : 2. [Nama Anggota 2 - NIM]
Kelas / Mata Kuliah	: Temu Kembali Informasi / Semester Ganjil 2026

RINGKASAN EKSEKUTIF

Laporan ini mendokumentasikan implementasi sistem pengumpulan koleksi dokumen web dari ANTARA News (antaranews.com) untuk topik **Musik Indonesia**. Dari 5.094 tautan kandidat yang ditemukan dan 2.007 URL unik, crawler berhasil mengekstrak 1.611 artikel, menyaring 1.000 artikel yang lolos validasi relevansi leksikal, dan menghasilkan **997 dokumen bersih** pasca-pembersihan dan deduplikasi ganda (URL + SHA-256). Seluruh atribut wajib (*doc_id, title, url, content, crawl_date*) terpenuhi tanpa missing value. Koleksi ini siap digunakan sebagai corpus Tugas 2 Classical Information Retrieval.

1. Sumber Website dan Alasan Pemilihan

Sumber data yang dipilih adalah portal berita nasional **ANTARA News (antaranews.com)**. Pemilihan sumber ini didasarkan pada empat pertimbangan utama:

- **Aksesibilitas Publik Penuh**: Dapat diakses gratis tanpa login, paywall, atau CAPTCHA bypass, menjamin etika crawling.
- **Konsistensi Struktur Teks**: Elemen judul (h1), lead paragraph, dan konten (div.post-content) terstandarisasi rapi.
- **Pengelompokan Tag Spesifik**: Menyediakan indeks tag terarah (/tag/musik-indonesia) untuk navigasi dokumen yang presisi.
- **Kelayakan Corpus IR**: Teks padat informasi dengan kosakata kaya yang sangat representatif untuk inverted index dan retrieval.

2. Topik dan Domain Dataset

Domain: Berita dan Kebudayaan Populer | **Topik:** Musik Indonesia.
Cakupan dokumen meliputi aktivitas musisi Tanah Air, rilis karya/album/singel, konser/festival, regulasi hak cipta dan royalti, serta ragam musik tradisional nusantara. Digunakan 5 Seed URLs utama: */tag/musik-indonesia* (utama), */tag/musisi-indonesia*, */tag/industri-musik*, */tag/musik*, dan */tag/lagu*.

3. Alur dan Proses Crawling

Alur kerja crawler mengikuti pipeline standar: **Website / Seed URL** → **Discovery (Pagination)** → **Article Crawling** → **Extraction & Relevance Filter** → **Cleaning & Deduplication** → **Dataset CSV**.

- **Validasi Etika robots.txt**: Pemeriksaan otomatis status HTTP 200 pada robots.txt menggunakan urllib.robotparser.RobotFileParser dengan User-Agent kustom: IR-Course-Crawler/1.0.
- **Discovery & Pagination Queue**: Penelusuran listing artikel menggunakan antrean deque dengan parsing pagination dinamis (/tag//) pada area konten utama.
- **Polite Crawling & Error Handling**: Request delay 1.5 detik per dokumen, timeout 20 detik, dan penanganan status HTTP 403, 404, 429, serta 5xx.

• **Ekstraksi Konten & Metadata**: Pemisahan elemen judul (h1.post-title), tanggal publikasi, dan isi utama (div.post-content) menggunakan BeautifulSoup.

• **Relevance Filter Dinamis**: Penyaringan leksikal berdasarkan hit kata kunci musik (MUSIC_TERMS) serta eliminasi berita bertopik luar (otomotif, teknologi AI, politik, militer, pariwisata).

• **Cleaning & Double Deduplication**: Penghapusan boilerplate ('Baca juga:', pewarta, editor), validasi panjang teks (>= 500 karakter), serta deduplikasi ganda (canonical URL + SHA-256 hash).

4. Struktur Dataset

Dataset disimpan dalam file CSV (UTF-8) dengan skema kolom terstruktur:

Field	Tipe	Status	Keterangan
doc_id	String	Wajib	ID unik setiap dokumen (D001 s.d. D997)
title	String	Wajib	Judul artikel berita bersih
url	URL	Wajib	Alamat kanonikal sumber artikel
content	Teks	Wajib	Isi teks berita utama (bebas boilerplate/iklan)
crawl_date	Datetime	Wajib	Waktu pengambilan (YYYY-MM-DD HH:MM:SS)
publication_date	ISO Datetime	Tambahan	Waktu publikasi resmi dari server berita
category	String	Tambahan	Rubrik pemberitaan
author	String	Tambahan	Entitas penerbit (antaranews.com)
source_tag	String	Tambahan	Tag seed penemu artikel kandidat

5. Hasil Crawling dan Statistik Eksekusi

Rekapitulasi metrik eksekusi aktual dari notebook Google Colab:

Metrik Evaluasi	Nilai Aktual	Keterangan
Candidate URLs Found	5.094	Total tautan yang terdeteksi pada listing tag
Unique Candidate URLs	2.007	URL artikel unik setelah deduplikasi antrean
Articles Extracted	1.611	Halaman artikel yang berhasil di-fetch dan diparsing
Relevant Articles	1.000	Artikel lolos filter leksikal topik musik
Irrelevant Discarded	611	Ditolak (subjek utama otomotif, AI, politik, dll.)
Failed / Empty Articles	4	Gagal unduh / respons halaman kosong
Discarded in Cleaning	3	Teks di bawah batas minimal (< 500 karakter)
Final Documents	**997**	**Koleksi dokumen bersih akhir dalam dataset CSV**

Kualitas Dataset: Tidak ditemukan nilai kosong (0 missing values), 0 URL duplikat, 0 duplikasi doc_id, dan 0 konten kosong. Jumlah 997 dokumen melampaui ketentuan minimal 100 dokumen.

6. Contoh Dokumen Hasil Crawling (5 Dokumen Teratas)

ID	Judul Artikel	URL Sumber	Cuplikan Isi (Snippet)
D001	**Gloria Jessica dan Ade Govinda rilis album...**	.../berita/5768940/gloria-jessica-dan-ade-govinda...	Jakarta (ANTARA) - Musisi Gloria Jessica dan Ade Govinda merilis album kolaborasi akustik...
D002	**700 delegasi musisi akan hadiri kegiatan KMI...**	.../berita/5765815/700-delegasi-musisi-akan-hadiri...	Makassar (ANTARA) - Pemkot Makassar mencatat 700 delegasi musisi hadir dalam Konferensi Musik...
D003	**Reality Club dan Phum Viphurit tampil di...**	.../berita/5765643/reality-club-dan-phum-viphurit...	Jakarta (ANTARA) - Synchronize Fest 2026 menghadirkan Reality Club & Phum Viphurit...
D004	**Project Pop satukan generasi lewat lagu di Pes...**	.../berita/5760947/project-pop-satukan-generasi...	Jakarta (ANTARA) - Grup musik Project Pop menghibur penonton lintas generasi dalam Pesta Musik...
D005	**Ndarboy dan Happy Asmara bawa musik Jawa...**	.../berita/5760409/ndarboy-dan-happy-asmara...	Jakarta (ANTARA) - Ndarboy Genk dan Happy Asmara membawakan lagu pop Jawa di festival musik...

7. Kendala yang Ditemukan dan Solusi Penanganannya

• **False Positive Tag ANTARA**: Tag 'musik' sering disematkan pada berita mobil dinas atau peresmian militer. Diatasi dengan filter leksikal multi-syarat yang menolak artikel berbobot musik rendah.

• **Paginasi Listing Dinamis**: Navigasi pagination antrean tag tidak selalu memiliki tombol next seragam. Diatasi dengan generator URL pagination berbasis slug rute ANTARA.

• **Pencegahan Rate Limit & Throttling**: Menghindari HTTP 429 dengan delay 1.5 detik per artikel, timeout 20 detik, dan pooling koneksi requests.Session.

• **Boilerplate Redaksional**: Pembersihan teks standar ('Baca juga:', pewarta, editor) via regex agar tidak mengotori vocab inverted index.

8. Kepatuhan terhadap robots.txt dan Etika Crawling

• **Status robots.txt**: Tervalidasi HTTP 200 di https://www.antaranews.com/robots.txt; hanya melarang /ajax/* dan /ucnews/*, memperbolehkan crawling konten umum.

• **Terms of Service**: Tervalidasi pada halaman ketentuan penggunaan untuk riset akademis non-komersial.

• **No Bypass & Privasi**: Tidak menggunakan pembobol paywall/CAPTCHA dan tidak mengambil data pribadi individu.

9. Keterkaitan dan Kesiapan Corpus untuk Tugas 2

Koleksi 997 dokumen bersih pada dataset_musik_indonesia_antara.csv sangat representatif untuk tahapan Tugas 2: Preprocessing teks (tokenisasi, stopwords, stemming), pembuatan Inverted Index, penerapan Boolean Retrieval, pembobotan TF-IDF / Vector Space Model, BM25, serta evaluasi sistem temu kembali informasi.